Warm-starting da otimização de hiperparâmetros

Johnattan D. F. Viana (jdfv@cin.ufpe.br)

Código, notebooks executados e matriz de perdas: github.com/johnattandouglas/DisciplinaMtL/tree/main/entrega3

1. Os meta-dados

Problema e datasets. Trocamos o problema das Atividades 1 e 2 pela meta-task de *warm-start* de HPO do paper do Dataset2Vec (D2V) [Jomaa et al. 2021, §6.3], que é a tarefa em que a pesquisa avalia representações de datasets. São 120 datasets de classificação do UCI — a coleção pré-processada de Fernández-Delgado et al. (2014), a mesma de onde vieram os 30 datasets da Atividade 1 —, com 16 a 130.064 instâncias (mediana 687), 3 a 262 atributos e 2 a 100 classes. A pergunta passa a ser *com qual configuração começar a busca* de um algoritmo já escolhido.

Algoritmo e espaço Θ. O algoritmo base é uma rede *feed-forward* (MLP) treinada por 50 épocas — o algoritmo da meta-task do D2V e um dos candidatos da Atividade 2. Θ tem 7 hiperparâmetros: ativação {ReLU, Leaky ReLU, SeLU}, forma da arquitetura {ASC, DES, ENC, SQU, SYM}, dropout {0; 0,2; 0,5}, camadas {1, 3, 5, 7}, neurônios {4, 8, 16, 32}, batch-norm {não, sim} e otimizador {Adam, RMSProp, SGD}. As **K = 3456** configurações são o **grid completo** (com 1 camada só existe a forma SQU, por isso não são 4320). A grade se justifica por ser o fatorial completo do meta-dataset: a matriz fica completa, sem imputação, e L* é exato. A **configuração padrão** é o ponto do grid mais próximo do default do `MLPClassifier` do scikit-learn (1 camada de 100 neurônios, ReLU, Adam, sem dropout/batch-norm): ReLU, SQU, dropout 0, 1 camada de 32 neurônios (a maior largura do grid), sem batch-norm, Adam.

Protocolo e custo. Todas as K × n células seguem o mesmo protocolo: a configuração é treinada na partição de treino do dataset e avaliada no hold-out de validação fixo do meta-dataset; **perda = 1 − acurácia de validação na época 50**. A matriz K × n = 3456 × 120 (`results/matriz_de_perdas.csv`) equivale a **414.720 treinos de 50 épocas**, pré-computados pelos autores do meta-dataset; nosso custo foi baixar ~1 GB e *canonizar* o grid (cada arquivo traz as configurações em outra ordem, e alguns repetem configurações). Usamos **T = 100** avaliações por busca (K = 3456 ≫ 3T = 300) e $\mathbf{n_{init} = 20}$ pontos iniciais (o protocolo do D2V), com **5 sementes** por (método, alvo). A matriz tem pouca resolução no topo: a mediana é de 44 valores distintos de perda por dataset (partições de validação pequenas) e em 18 datasets ≥ 1% das configurações empatam no ótimo — empates que desfazemos por sorteio com a semente.

2. Métodos

Para cada alvo d_t (leave-one-dataset-out), avaliar uma configuração é ler a célula de d_t; todo o meta-conhecimento (vizinhos, ranks médios, normalização das meta-características) vem só dos outros 119. Comparamos: (1) **Padrão**; (2) **Random Search** sem reposição; (3) **SMBO frio**, 20 configurações aleatórias + SMBO; (4) **WS-⟨rep⟩**, cujos 20 pontos iniciais vêm dos k datasets mais próximos de d_t no espaço ⟨rep⟩, em rodízio (a melhor configuração de cada vizinho, depois a 2ª melhor de cada um, …; com k = 1 são as 20 melhores do vizinho mais próximo, como no D2V, e com k ≥ 20 seria exatamente Feurer et al. (2014)); e (5) **WS independente**, as 20 configurações de melhor rank médio nos 119 datasets de treino. Os métodos 3–5 usam o mesmo SMBO: **GP com kernel Matérn 3/2 e ARD** (hiperparâmetros reotimizados a cada iteração) sobre a codificação one-hot das configurações e **Expected Improvement** sobre as configurações ainda não avaliadas. A comparação principal usa **k = 1**, fixado a priori; k ∈ {1, 3, 5} entra na Análise 2, junto com um controle extra, **WS-Random**: o método 4 com uma representação aleatória (32 dims ~ U(−1, 1)), isto é, k datasets *arbitrários* no lugar dos mais similares.

Meta-características. *Clássicas*: **PyMFE** (`MFE()` padrão [Alcobaça et al. 2020]; 102 colunas após a limpeza), **MF1** (Wistuba et al. 2016; 28) e **MF2** (Feurer et al. 2015; 22). *Aprendidas*: **D2V** (32 dims) e a nossa **Our-Trained** (1024 dims): um encoder de atenção invariante a permutações sobre o dataset bruto → MLP → z, treinado com entropia cruzada para prever, para cada um dos 7 hiperparâmetros, a distribuição de valores entre as 20 melhores configurações do dataset — um alvo específico desta meta-task. D2V e Our-Trained têm um extrator por split oficial do D2V (80/16/24 datasets de treino/validação/teste); o alvo usa o extrator do split em que ele é de teste, que nunca o viu. Para cada alvo, descarte de colunas com NaN, imputação e min-max são ajustados nos outros 119; a distância é euclidiana.

Métricas. Perda normalizada da melhor configuração até a avaliação i, $(L - L^*)/(L_{pior} - L^*)$ por dataset, média sobre sementes e datasets (o ADTM do D2V); **AUC** = média dessa curva em i = 1..T; rank médio entre métodos (a outra métrica do D2V). Testes: Friedman com diferença crítica de Nemenyi [Demšar 2006] (α = 0,05; N = 120

datasets como blocos, sementes agregadas pela média) e Wilcoxon pareado com correção de Holm para os pares de interesse.

3. Resultados

3.1 Análise 1 — Curvas de perda

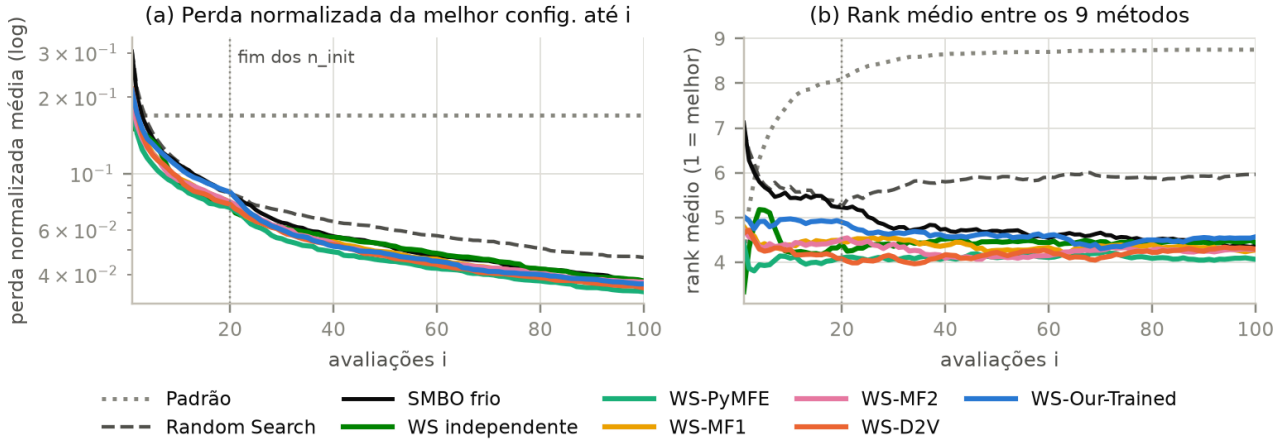


Figura 1. (a) Perda normalizada da melhor configuração até a avaliação i (média sobre 120 alvos × 5 sementes; escala log) e (b) rank médio entre os 9 métodos a cada avaliação. Warm-start por similaridade com k = 1. A linha pontilhada vertical marca o fim dos n_{init} = 20 pontos iniciais.

Tabela 1. Perda normalizada média logo após os pontos iniciais (t = 20), em um orçamento intermediário (t = 50) e em T = 100; AUC = média da curva em i = 1..100; rank médio da AUC entre os 9 métodos. Menor = melhor; † = melhor que o SMBO frio (Wilcoxon pareado, Holm, α = 0,05).

Método	t = 20	t = 50	t = 100	AUC	rank (AUC)
WS-PyMFE	**0,073 †**	**0,045**	**0,034**	**0,055 †**	**3,95**
WS-D2V	0,076 †	0,048	0,035	0,058	4,01
WS-MF2	0,077	0,047	0,037	0,059	4,19
WS-MF1	0,077	0,049	0,036	0,059	4,35
WS-Our-Trained	0,085	0,048	0,037	0,061	4,53
WS independente (método 5)	0,076	0,053	0,038	0,060	4,14
SMBO frio (método 3)	0,084	0,052	0,038	0,065	5,40
Random Search (método 2)	0,083	0,061	0,047	0,072	6,07
Padrão (método 1)	0,170	0,170	0,170	0,170	8,36

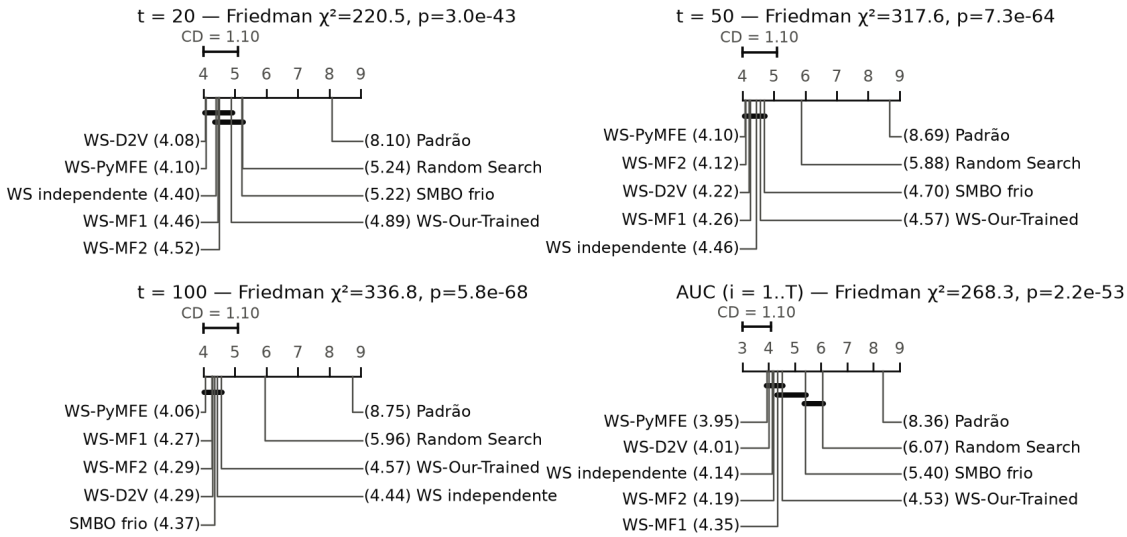


Figura 2. Diagramas de diferença crítica (Friedman + Nemenyi, α = 0,05, N = 120, CD = 1,10) em t = 20, t = 50, t = 100 e na AUC. Barras grossas ligam métodos cuja diferença de rank médio não excede a CD.

O teste de Friedman rejeita a igualdade em todos os orçamentos (χ^2 = 220,5 em t = 20 até 336,8 em t = 100; $p < 10^{-42}$), mas boa parte disso vem do Padrão e do Random Search. Entre os SMBO, o quadro muda com o orçamento. **Logo após os pontos iniciais** (t = 20), os warm-starts por WS-D2V e WS-PyMFE ficam a mais de uma CD do SMBO frio e do Random Search, e também vencem o SMBO frio no Wilcoxon-Holm (p = 0,04 e 0,03); a perda média cai de 0,084 para 0,073–0,076. Em **t = 50** nenhum par de SMBO difere após a correção de Holm, e em **T = 100** todos os SMBO formam um único grupo (perdas de 0,034 a 0,038, $p_{Holm} \geq 0{,}46$). Na AUC, que integra a curva, todos os warm-starts por similaridade, exceto Our-Trained e MF1, ficam a mais de uma CD do SMBO frio, mas só o WS-PyMFE passa no Wilcoxon-Holm (p = 0,002). O rank médio por avaliação (Fig. 1b) mostra a mesma coisa: os warm-starts lideram desde a 1ª avaliação e o SMBO frio alcança o grupo perto de i = 80. **O warm-start ajuda no começo; a vantagem não persiste até T** — o GP com EI recupera o atraso em ~60 avaliações. O WS-Our-Trained é a exceção: em t = 20 ele não difere do SMBO frio (0,085 × 0,084).

3.2 Análise 2 — O papel das meta-características

Tabela 2. Warm-start por similaridade (método 4) com k vizinhos, comparado ao WS independente (método 5, t = 20: 0,076; AUC: 0,060) e ao controle WS-Random, que usa k datasets *arbitrários*. * = melhor que o WS independente (Wilcoxon-Holm sobre 18 comparações); ‡ = melhor que o WS-Random com o mesmo k (Wilcoxon-Holm sobre 30 comparações); α = 0,05.

Representação	perda em t = 20			AUC (i = 1..100)		
	k = 1	k = 3	k = 5	k = 1	k = 3	k = 5
PyMFE (clássica)	0,073	0,064	0,064	0,055	0,053	0,052 ‡
MF1 (clássica)	0,077	0,067	**0,060** *	0,059	0,055	**0,051** ‡
MF2 (clássica)	0,077	0,067	0,062 ‡	0,059	0,055	0,052 ‡
D2V (aprendida)	0,076	0,067	0,063	0,058	0,055	0,054
Our-Trained (aprendida)	0,085	0,069	0,063	0,061	0,057	0,054
Random (controle)	0,082	0,072	0,071	0,062	0,059	0,059

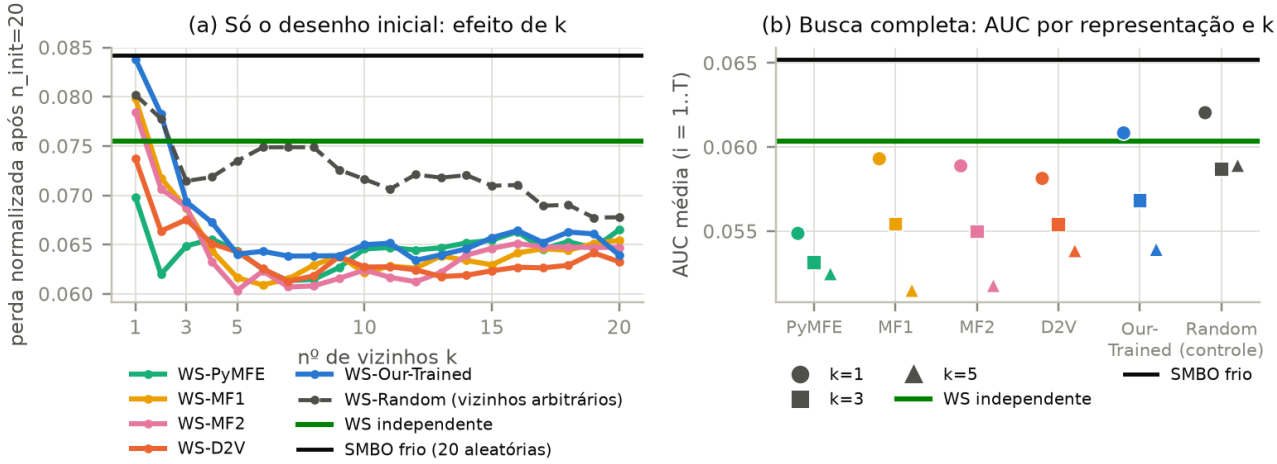


Figura 3. (a) Só a fase inicial (sem SMBO): perda normalizada após os 20 pontos do warm-start em função do número de vizinhos k, calculada exatamente para k = 1..20 (média sobre alvos e 5 sorteios de empates). (b) AUC da busca completa por representação e k.

Método 4 × método 5. Com k = 1, nenhum warm-start por similaridade difere do WS independente em orçamento algum ($p_{Holm} \geq 0{,}76$ na AUC); o melhor deles, PyMFE, vence o controle em 65 alvos e perde em 54. **Clássicas × aprendidas:** a AUC média das aprendidas (0,0595) não difere da das clássicas (0,0577; Wilcoxon p = 0,34). O vizinho escolhido é pouco melhor que um dataset qualquer: na matriz M[i, j] (perda em i usando as 20 melhores configurações de j), ele fica no percentil 42 (PyMFE), 44 (D2V), 48 (MF1, MF2) e 52 (Our-Trained) dos 119 candidatos, contra 50 de um vizinho aleatório e uma perda de 0,008 do melhor vizinho possível (oráculo) — há muito a ganhar com um vizinho certo, e as meta-características quase não o encontram. Só o D2V tem distância correlacionada com a utilidade do vizinho (ρ médio = 0,06, p = 0,0002), e mesmo assim fracamente — a representação aleatória chega a ρ = 0,02 (p = 0,03); nas demais ρ ≈ 0. As representações também quase nunca concordam: escolhem o mesmo vizinho em 2–22% dos alvos (MF1 e MF2, 65%).

Efeito de k. Aumentar k ajuda todas as representações: em t = 20 a perda cai de 0,073–0,085 (k = 1) para 0,060–0,064 (k = 5), e o WS-MF1 com k = 5 passa a vencer o WS independente (p_{Holm} = 0,01). A Fig. 3a mostra que, a partir de k ≈ 5, as curvas de todas as representações se sobrepõem em 0,060–0,065 — abaixo do controle com vizinhos arbitrários, que estaciona em 0,068–0,075. Há, portanto, dois efeitos. (i) **Agregar** as melhores configurações de vários datasets já ajuda por si: na busca completa, o WS-Random cai de 0,082 (k = 1) para 0,071 (k = 5) em t = 20, nominalmente abaixo do WS independente. (ii) **Escolher** esses datasets por similaridade acrescenta um ganho que só aparece com k = 5: as três clássicas vencem o WS-Random na AUC (PyMFE, MF1 e MF2: p_{Holm} = 0,013, 0,015 e 0,004; melhores em 74–77 dos 120 alvos) e o MF2 também em t = 20 (p_{Holm} = 0,02); D2V (0,16) e Our-Trained (0,54) não. Com k = 1 ou 3, nenhuma representação supera vizinhos arbitrários ($p_{Holm} \geq 0,49$). **A similaridade orienta a escolha, mas fracamente:** um único vizinho é ruidoso demais, e o sinal só aparece ao agregar alguns vizinhos — e só com as meta-características clássicas.

3.3 Análise 3 — Quando o warm-start falha

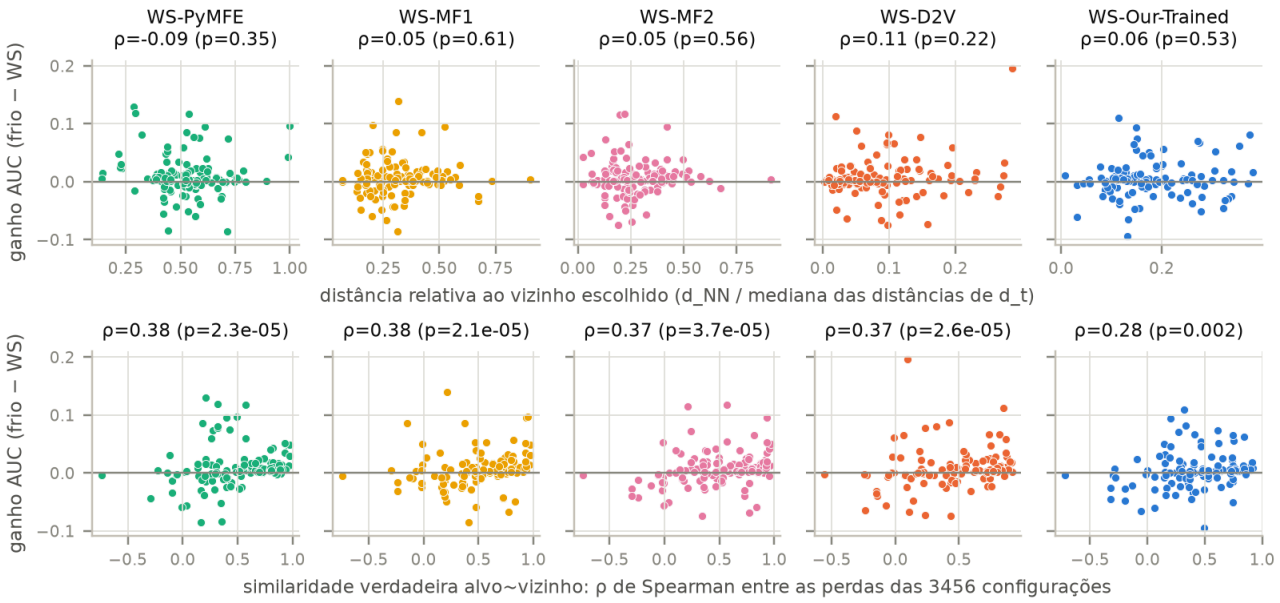


Figura 4. Ganho do método 4 (k = 1) sobre o método 3 por alvo, ganho = AUC(SMBO frio) − AUC(WS) (> 0: o warm-start ajudou), contra (linha de cima) a distância relativa do alvo ao vizinho escolhido e (linha de baixo) a similaridade "verdadeira" entre os dois — o ρ de Spearman entre as perdas das 3456 configurações nos dois datasets.

O warm-start (k = 1) é melhor que partir do zero em 76–82 dos 120 alvos e pior em 38–44, conforme a representação. **O ganho não se relaciona com a distância ao vizinho** em nenhuma representação: ρ de Spearman entre ganho e distância relativa de −0,09 (PyMFE) a 0,11 (D2V), todos com p ≥ 0,22 (o mesmo com a distância absoluta). Estar "perto" no espaço de meta-características não indica que o vizinho é útil. O que explica o ganho é a **similaridade verdadeira** entre as paisagens de perda do alvo e do vizinho (ρ = 0,28–0,38 com o ganho, Fig. 4 embaixo): nos alvos em que o warm-start perdeu, a mediana dessa similaridade é 0,22–0,35, contra 0,60–0,72 nos alvos em que ganhou (Mann-Whitney, $p \leq 6\times10^{-5}$), e os 20 pontos herdados deixam o alvo com perda 0,10–0,12, contra 0,02–0,03. Exemplos: o Our-Trained manda *cardiotocography-3clases* para *bank* (ρ = −0,32, quando havia um vizinho com ρ = 0,92) e *wine-quality-white* para *post-operative* (ρ = −0,05; melhor possível 0,81); o D2V manda *breast-cancer-wisc-prog* para *oocytes_merluccius_nucleus_4d* (ρ = −0,24). A falha depende mais do alvo do que da representação: os ganhos das cinco representações se correlacionam (ρ = 0,27–0,67), e em 10 alvos todas perdem para o SMBO frio — *lung-cancer*, *post-operative*, *heart-switzerland*, *echocardiogram*, *parkinsons*, *contrac*, *monks-1*, *mammographic*, *pittsburg-bridges-MATERIAL* e *vertebral-column-2clases*. São, em geral, datasets pequenos (32 a 1.473 instâncias; os alvos em que o warm-start falha são menores que aqueles em que ele ganha, p ≤ 0,004 para D2V e MF1): com poucas instâncias de validação a perda é ruidosa e de baixa resolução, a paisagem de um dataset pouco diz sobre a de outro e, quando muitas configurações empatam no ótimo (9% em *lung-cancer*), 20 pontos aleatórios já bastam.

4. Interpretação

O warm-start acelerou a busca? Sim, mas só no começo. Os 20 pontos herdados reduzem a perda em t = 20 em até 13% em relação ao SMBO frio (significativo para PyMFE e D2V) e a vantagem diminui depois: em t = 50 já não é significativa e em T = 100 todos os SMBO empatam. Ele ajuda em cerca de 2/3 dos alvos — naqueles cuja paisagem de perda se parece com a de algum dataset de treino — e atrapalha nos datasets pequenos e ruidosos, em que o vizinho transfere configurações que só eram boas para ele.

O ganho vem das meta-características ou do portfólio? Principalmente do portfólio. No protocolo do D2V (k = 1), o warm-start por similaridade não supera nem o WS independente nem vizinhos arbitrários: o ganho sobre a partida fria vem de começar por configurações que são boas em *algum* dataset, não de achar o dataset certo — o vizinho escolhido fica perto do percentil 50 dos candidatos, enquanto o oráculo mostra que o vizinho certo levaria a perda inicial de 0,08 a 0,008. O sinal das meta-características existe, mas é pequeno e só aparece com k = 5 e com as clássicas: perto do efeito de agregar (0,082 → 0,071 com vizinhos arbitrários), escolhê-los por similaridade acrescenta 0,071 → 0,060–0,064 em t = 20. As aprendidas não superaram as clássicas (p = 0,34). O próprio controle do método 5 é um portfólio fraco: o rank médio escolhe configurações boas "na média" e parecidas entre si, e fica, nominalmente, atrás das melhores configurações de 5 datasets arbitrários; um portfólio guloso, que minimiza a perda do melhor ponto do conjunto, seria um controle mais exigente.

O que a restrição às K configurações pode ter escondido. A busca simulada torna o experimento possível — 13.200 buscas (22 variantes × 120 alvos × 5 sementes) custaram 26,7 h de CPU (2,5 h em 11 núcleos), contra o equivalente a ~1,3 milhão de treinos reais —, mas tem preço. (i) L* é o ótimo *do grid*: taxa de aprendizado, tamanho do lote e número de épocas estão fixos, então não sabemos quanto o grid deixa de fora nem se o warm-start ajudaria num espaço contínuo, onde as configurações de um vizinho não existem exatamente no alvo e teriam de ser mapeadas. (ii) Transferir configurações idênticas é o caso mais favorável ao warm-start; com GP sobre um espaço contínuo, o desenho inicial pesaria menos. (iii) O custo é contado em avaliações, não em tempo: uma rede de 7 camadas custa mais que uma de 1, e o warm-start pode herdar configurações caras. (iv) A resposta é de baixa resolução (mediana de 44 valores distintos de perda por dataset) e o ótimo de validação nem sempre é o de teste: escolhê-lo custa, em mediana, 4,3 p.p. de acurácia de teste em relação ao ótimo de teste (ρ validação~teste = 0,72) — parte das "melhores configurações" transferidas é ruído de um hold-out pequeno.

O que levo para a pesquisa. (1) A Our-Trained de 1024 dimensões foi o pior warm-start, e o diagnóstico de treino explica por quê: o alvo (a distribuição dos hiperparâmetros das top-20 configurações) é previsto tão bem por uma distribuição constante quanto pelo modelo (CE de validação 1,081–1,140 contra 1,092–1,141 do prior constante), logo nada obriga z a separar datasets — a dimensão maior não compensa um objetivo que não exige similaridade. O objetivo deveria ser relacional, alinhando distâncias em z à similaridade de paisagem (o ρ que explicou as falhas) ou à matriz de transferência M. (2) Avaliar uma representação para warm-start exige os controles de portfólio e de vizinhos arbitrários; compará-la só com a partida fria atribui à representação um ganho que é do portfólio. (3) Desenhos com vários vizinhos (k = 5) são mais robustos que copiar as 20 melhores de um só dataset, como no protocolo original do D2V — e é só com eles que a similaridade se mostra útil.

Referências

Demšar, J. (2006). Statistical comparisons of classifiers over multiple data sets. *JMLR*, 7:1–30.

Fernández-Delgado, M., Cernadas, E., Barro, S. e Amorim, D. (2014). Do we need hundreds of classifiers to solve real world classification problems? *JMLR*, 15:3133–3181.

Feurer, M., Springenberg, J. T. e Hutter, F. (2014). Using meta-learning to initialize Bayesian optimization of hyperparameters. *MetaSel@ECAI*, 3–10.

Feurer, M., Springenberg, J. T. e Hutter, F. (2015). Initializing Bayesian hyperparameter optimization via meta-learning. *AAAI*, 1128–1135.

Jomaa, H. S., Schmidt-Thieme, L. e Grabocka, J. (2021). Dataset2Vec: learning dataset meta-features. *Data Mining and Knowledge Discovery*, 35:964–985.

Wistuba, M., Schilling, N. e Schmidt-Thieme, L. (2016). Two-stage transfer surrogate model for automatic hyperparameter optimization. *ECML-PKDD*, 199–214.

Alcobaça, E. et al. (2020). MFE: towards reproducible meta-feature extraction. *JMLR*, 21(111):1–5.