

IN1097 · Tópicos Avançados em Agentes Inteligentes 2

Avaliando Recomendações de Sistemas de Meta-aprendizagem e AutoML

Aula 5

Profa. Juscimara G Avelino

Onde paramos

- Construimos a **matriz de performances** P e a convertemos na **matriz de ranks** R
- Agregamos os rankings por **rank médio, rank mediano e vitórias significativas**
- Distinguimos as duas formas de treinar um meta-modelo de ranking — e vimos a via híbrida
- **Como saber se um ranking recomendado é bom?**

Objetivos

- Separar avaliação em **nível base** de avaliação em **meta-nível**
- Justificar por que **performances precisam ser normalizadas** antes de comparar datasets
- Aplicar **correlação de ranks** para comparar um ranking predito com o padrão ouro
- Interpretar **curvas de perda** por número de testes e por tempo acumulado
- Comparar sistemas com **testes estatísticos e diagramas de diferença crítica**

Dois níveis, duas perguntas diferentes

Meta-nível

qualidade da predição

- O meta-modelo acertou a ordem?
- Compara predição com o meta-alvo
- Medidas: correlação de ranks, acuracia, f1-score, MSE, MAE

Nível base

efeito da recomendação

- Quanto o usuário ganha ao seguir?
- Simula a avaliação sequencial no dataset alvo
- Medidas: perda de performance, curvas de perda

Estratégias de Avaliação

Holdout

- Uma divisão treino/teste
- A proporção afeta a estimativa

Validação cruzada

- k folds, k avaliações agregadas
- Menor variabilidade que o holdout

Leave-one-out

- Caso extremo: $k = n$
- Viável quando há poucas instâncias

PARTE 1

Normalização da performance

90% não quer dizer a mesma coisa em dois datasets

O problema

Uma acurácia de 90% pode ser bastante alta em um problema de classificação — e baixa em outro

- A faixa de variação da performance difere substancialmente entre datasets
- Se queremos comparar sistemas ao longo de vários datasets, é preciso reescalar os valores
- Sem isso, a média entre datasets é dominada pelos datasets fáceis

Cinco abordagens

- 1 Substituir por ranks** Cada linha vira uma ordenação – Aula passada
- 2 Reescalar no intervalo 0–1** Min-max; o pior costuma ser o classificador default
- 3 Mapear em distribuição normal** Z-score; assume normalidade
- 4 Reescalar em quantis** Pontos de corte com probabilidades iguais
- 5 Normalizar pela margem de erro** Quantas margens abaixo do melhor — Gama e Brazdil (1995)

PARTE 2

Avaliando o sistema de MtL/AutoML

Onde o dataset vira instância

Dois modos de avaliação

1 · Etapa única com hold-out

- A avaliação é feita uma só vez
- Divisão treino/teste definida pelo usuário
- Fora do escopo do sistema avaliado
- Produz um único resultado

2 · Validação cruzada

- Um ciclo seguindo CV ou LOO
- Os datasets base são tratados como instâncias
- Um resultado por fold, depois agregados
- Menor dispersão, menor influência da sorte

O objetivo, formalizado


O objetivo de um sistema de MtL/AutoML pode ser escrito como a minimização de uma perda.

$$a_{\theta^*}^* = \arg \min_{a^j \in \mathcal{A}, \theta \in \Theta^j} \mathcal{L}(a_{\theta}^j, d_{train}, d_{valid}).$$

- Buscamos simultaneamente o algoritmo e a sua configuração
- Nesse processo o próprio sistema conduz avaliações internas para chegar à recomendação

A avaliação interna do sistema

- O sistema não pode — e não deve — usar o conjunto de teste de forma alguma
- Por isso o treino é subdividido em treino interno e validação
- A variante com melhor performance na validação é selecionada, e pode ser retreinada em todo o treino
- Só então o modelo é avaliado no teste, e o resultado é reportado ao usuário



subdivisão interna do sistema

Evitando avaliação enviesada

um dataset usado para avaliar o sistema não pode estar no meta-dataset com que o sistema foi construído

- Lembre-se: no meta-nível, dataset = instância. É o mesmo vazamento de sempre, um nível acima
- Alguns sistemas, como o Auto-sklearn, já vêm com um meta-dataset de datasets comuns de benchmark
- Ao comparar esse sistema com outro, os datasets de avaliação precisam ser diferentes dos que ele já conhece

Avaliação com consulta a tabela

- Avaliar algoritmos em nível base é computacionalmente caro
- Estratégia: a performance de cada algoritmo em cada dataset é avaliada uma vez e registrada no meta-dataset
- Sempre que for preciso repetir a mesma avaliação, o resultado é recuperado por uma consulta à tabela
- Isso viabiliza avaliação em larga escala: os experimentos podem ser refeitos sem custo computacional adicional


PARTE 3

Avaliação por correlação

Comparando o ranking predito com o padrão ouro

O padrão ouro

- A qualidade do ranking recomendado é estabelecida por comparação com o ranking ideal no dataset de teste
- Esse ranking ideal também é chamado de ranking verdadeiro (true ranking)
- Em cada ciclo leave-one-dataset-out, comparamos o recomendado com o verdadeiro — e depois tiramos a média



Correlação de Spearman

rank
predito rank
verdadeir

ϕ

$$r_s(\hat{R}, R) = \frac{\sum_{i=1}^n (\hat{R}_i - \bar{\hat{R}})(R_i - \bar{R})}{\sqrt{(\sum_{i=1}^n (\hat{R}_i - \bar{\hat{R}})^2 \sum_{i=1}^n (R_i - \bar{R})^2)}}$$

- **Mede a associação** entre o ranking predito e o ranking verdadeiro, comparando as posições relativas dos itens.
- O valor varia de -1 a 1 :
 - 1 – concordância **perfeita** entre os rankings;
 - 0 – **ausência** de associação monotônica;
 - -1 – ordenação completamente **inversa**.
- 0 é o valor esperado para um método de **ranking aleatório**, pois não há associação sistemática entre o ranking predito e o verdadeiro.

Exemplo — o dataset letter

	C5b	C5r	C5t	MLP	RBFN	LD	Lt	IB1	NB	RIP
Recomendado	1,5	5,5	7	9	10	4	3	1,5	5,5	8
Verdadeiro	1	3	5	7	10	8	4	2	9	6

$$rs = 0,707$$

Medida ponderada de correlação de rank

Spearman tem a desvantagem de tratar todos os ranks igualmente. Um erro no 1º lugar pesa o mesmo que um erro no 9º.

$$r_w(\hat{R}, R) = 1 - \frac{6 \sum_{i=1}^n (\hat{R}_i - R_i)^2 ((n - \hat{R}_i + 1) + (n - R_i + 1))}{n^4 + n^3 - n^2 - n}$$

Erro	Peso
Era 1º, previsto como 2º	$(10 - 2 + 1) + (10 - 1 + 1) = 9 + 10 = 19$
Era 9º, previsto como 10º	$(10 - 10 + 1) + (10 - 9 + 1) = 1 + 2 = 3$

As medidas comparadas

Cinco rankings comparados contra o verdadeiro $A = (1, 2, 3, 4, 5, 6)$:

Ranking		Spearman	Rank pond.
B (1 2 3 4 5 6)	idêntico	1,00	1,00
C (2 1 3 4 5 6)	troca no topo	0,94	0,91
D (1 2 3 4 6 5)	troca no fim	0,94	0,98
E (6 5 4 3 2 1)	invertido	-1,00	-1,00

PARTE 4

Avaliando os efeitos das recomendações


Descendo de volta ao nível base

Perda de performance


$$\text{perda} = \text{performance de } a^* - \text{performance de } \hat{a}^*$$

- $\hat{a}^*$ é o melhor algoritmo identificado pelo sistema até um dado momento
- a^* é o algoritmo verdadeiramente melhor, aquele que conhecemos
- Em muitos casos o verdadeiramente melhor não é conhecido — usa-se um proxy, como o encontrado após uma busca bem longa
- **A perda começa alta e cai conforme o usuário desce na lista recomendada**

Curva de perda por número de testes



Curva perda-tempo



Testes estatísticos

Mostrar que um método é mais acurado que outro em média não é argumento suficientemente convincente: os valores comparados são estimativas obtidas em uma amostra de datasets, e têm variância.

- Os números comparados podem ser coeficientes de correlação (meta-nível) ou valores que caracterizam curvas de perda (nível base)
- No segundo caso: performance em um dado orçamento de tempo, ou a AUC em um intervalo
- Com dois ou mais métodos sobre múltiplos datasets, segue-se o procedimento de comparação múltipla de Demšar (2006)

O procedimento

- Teste de Friedman; se ele indica diferenças significativas, segue-se um teste post hoc — Nemenyi ou Dunn

Diagrama de diferença crítica

