

Meta-dataset e ranking de algoritmos

Johnattan D. F. Viana (jdfv@cin.ufpe.br)

Repositório: <https://github.com/johnattandouglas/DisciplinaMtL>

1. Criação do meta-dataset

Datasets. Foram utilizados 30 conjuntos de dados reais de classificação supervisionada do UCI Machine Learning Repository¹. Os datasets não possuem valores nulos.

Meta-alvo. Como meta-target, adotou-se a acurácia de cinco algoritmos de famílias distintas [Fernández-Delgado et al. 2014]: Decision Tree (DT), Random Forest (RF), Support Vector Machine (SVM), Naive Bayes (NB) e k -Nearest Neighbors (KNN). Foi considerado a configuração padrão do scikit-learn [Pedregosa et al. 2011] para todos os algoritmos. A acurácia foi escolhida por ser interpretável, dado que a coleção é exclusivamente de classificação com desbalanceamento moderado. Em cada dataset, os cinco classificadores foram avaliados por 10 repetições de hold-out estratificado (80/20) sobre as mesmas partições. A validação cruzada estratificada foi inviável nos datasets que tinham classes com pouquíssimas instâncias. Ao todo, foram realizadas 1500 ($30 \times 5 \times 10$) medições de desempenho dos modelos-base. Quando aplicável, adotou-se o Random Forest como meta-modelo.

Meta-características. Os datasets foram descritos por meta-características extraídas com PyMFE [Alcobaça et al. 2020] em configuração padrão, abrangendo todas as famílias da biblioteca. Das 179 extraídas, 46 foram descartadas por conterem valores ausentes, restando 133.




Figure 1. Perfil dos cinco modelos-base sobre os datasets utilizados.

2. Resultados e Discussões

A Figura 1 resume o comportamento dos cinco algoritmos sobre os datasets por três perspectivas complementares. Na Figura 1(a), a acurácia média com desvio padrão mostra RF ($0,827 \pm 0,119$) e SVM ($0,819 \pm 0,124$) praticamente indistinguíveis no topo, seguidos por KNN ($0,788$), DT ($0,769$) e NB ($0,707$). Na Figura 1(b), apresentamos o rank médio dos algoritmos ao longo dos 30 conjuntos de dados, correspondente à posição ocupada por cada método quando os cinco algoritmos são ordenados segundo a acurácia média obtida em cada conjunto.

Na Figura 1(c), a matriz W_{ij} conta em quantos dos 30 datasets o algoritmo da linha i superou o da coluna j com significância estatística, considerando $\alpha = 0,05$ no Wilcoxon signed-rank pareado sobre os 10 folds. Como $W_{ij} + W_{ji} \leq 30$, o resíduo mede empates estatísticos: RF e SVM só se separam em 13 dos 30 datasets (placar de 9 a 4 para o RF), ao passo que o NB nunca

¹<https://archive.ics.uci.edu/>

vence o RF de forma significativa (0 em 30). Vale ressaltar que os poucos acertos do DT contra RF e SVM (1 e 4) não são ruído, são os datasets onde o consenso falha (*lenses*, *nursery*, *titanic*), exatamente as exceções que um meta-modelo baseado em X precisaria detectar para superar o consenso fixo, única forma de compensar seu custo adicional de extração de meta-características e treinamento.

Essa métrica permite tornar os conjuntos de dados comparáveis entre si, uma vez que uma acurácia de 0,74 pode ser considerada baixa em um conjunto de dados relativamente simples e, simultaneamente, elevada em um conjunto de dados mais desafiador; contudo, tal abordagem desconsidera a magnitude absoluta das diferenças de desempenho entre os algoritmos. Observa-se que se considerarmos apenas o número de vitórias absolutas, o SVM apresenta desempenho superior (13 datasets, em comparação a 12 do RF); contudo, segundo o critério de rank médio, a ordenação se inverte (1,93 para o RF versus 1,97 para o SVM). Embora a diferença seja pequena, ela é suficiente para determinar qual algoritmo é colocado em primeiro lugar pelo consenso e, consequentemente, constitui a origem da instabilidade do AR discutida posteriormente.




Figure 2. Curva de perda por número de testes.

Quanto aos algoritmos testados, na Figura 2 observa-se que a curva de perda decresce acentuadamente até $t = 2$ e torna-se praticamente nula a partir de $t = 3$. As cinco primeiras abordagens apresentam convergência, em $t = 2$, para aproximadamente $2,6 \times 10^{-3}$, valor correspondente a 0,26 ponto percentual de acurácia. O HARRIS também exibe baixa perda nesse instante, com $9,16 \times 10^{-3}$. Assim, a avaliação dos dois primeiros algoritmos da lista recomendada já conduz a desempenho próximo ao do melhor algoritmo, sugerindo que a maior parcela da variação entre as abordagens decorre da seleção do algoritmo inicial.




Figure 3. Detalhamento dos experimentos com HARRIS.

A Figura 3 indica que nenhum λ aproxima o HARRIS do MR em $t = 1$, embora a partir de $t = 3$ as curvas converjam. Com λ de 0 a 1, a AUC sobe de $13,33 \times 10^{-3}$ para $18,70 \times 10^{-3}$ e o $\bar{\rho}$ cai de 0,267 para 0,141. Contudo, o teste de Friedman não apontou diferenças significativas entre λ para Spearman ($p = 0,486$) ou AUC ($p = 0,682$). O melhor resultado ocorreu em $\lambda = 0$, contrariando a premissa de que valores intermediários de λ seriam superiores.

Como detalhado na Tabela 1, as abordagens treinadas não superaram as agregações de ranking. O melhor meta-modelo treinado (Abordagem 1) obteve 0,644, enquanto o rank mediano (MR) alcançou 0,649. Além disso, na Figura 4, o pós-teste de Nemenyi não identificou diferenças estatisticamente significativas entre AR, MR, Vitórias Significativas, Abordagem 1 e Abordagem 2. Isso pode ser consequência do ranking de consenso já apresentar concordância de 76,3% com as 300 comparações par-a-par individuais. Além disso, a exclusão de meta-features eliminou todas as 14 meta-características da família de *landmarking*, que fornece informações relacionadas ao desempenho de algoritmos e, conseqüentemente, são relevantes para tarefas de seleção de algoritmos, justamente porque já são uma amostra direta do comportamento de classificadores naquele dataset [Bilalli et al. 2017].

Table 1. Resultados das abordagens avaliadas.

Approach	Spearman	AUC	Rank Spearman	Rank AUC
MR	0.6493 ± 0.3154	0.0039 ± 0.0062	2.8833	3.1333
Abordagem 1	0.6444 ± 0.3050	0.0039 ± 0.0062	2.9167	3.1333
Vitórias significativas	0.6344 ± 0.3124	0.0039 ± 0.0062	2.8667	3.1333
Abordagem 2	0.5938 ± 0.3790	0.0046 ± 0.0066	3.2500	3.3667
AR	0.5810 ± 0.3157	0.0065 ± 0.0083	4.0500	3.6833
HARRIS ($\lambda = 0.5$)	0.2501 ± 0.4468	0.0144 ± 0.0198	5.0333	4.5500




Figure 4. Diagramas de Diferença Crítica. (a) Estatística do teste=37.180, p-valor=0.000, CD = 1.377; (b) Estatística do teste=22.460, p-valor=0.000, CD = 1.377

Em resumo, os resultados alcançados evidenciam que as abordagens treinadas não superaram as agregações. Cinco das seis formam um bloco estatisticamente indistinguível ($\bar{\rho}$ entre 0,581 e 0,649), liderado pelo rank mediano (MR), enquanto apenas o HARRIS se separa. Como dito anteriormente, o consenso já acerta 76,3% das comparações par-a-par. Assim, a Abordagem 1 reproduz a ordem do MR em 28 dos 30 datasets, indicando que aprendeu principalmente o consenso. MR e vitórias significativas apresentam comportamento praticamente idêntico, enquanto o AR é mais instável devido à proximidade entre RF e SVM, cuja troca de posição reduz o acerto de top-1 de 40% para 20%. A Abordagem 2 é a que mais se distancia do consenso, concordando com o MR em 15/30 datasets, mas apresenta maior variabilidade.

Por fim, todas as abordagens falham nos mesmos quatro datasets (*lenses*, *echocardiogram*, *iris* e *mammographic*) que constituem exceções ao consenso e para as quais as meta-características disponíveis não fornecem informação suficiente para generalização.

References

- Alcobaça, E., Siqueira, F., Rivolli, A., Garcia, L. P. F., Oliva, J. T., and de Carvalho, A. C. P. L. F. (2020). Mfe: Towards reproducible meta-feature extraction. *Journal of Machine Learning Research*, 21(111):1–5.
- Bilalli, B., Abelló, A., and Aluja-Banet, T. (2017). On the predictive power of meta-features in openml. *International Journal of Applied Mathematics and Computer Science*, 27(4):697–712.
- Fernández-Delgado, M., Cernadas, E., Barro, S., and Amorim, D. (2014). Do we need hundreds of classifiers to solve real world classification problems? *The journal of machine learning research*, 15(1):3133–3181.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., et al. (2011). Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830.